Universidad de SanAndrés

I302 - Aprendizaje Automático y Aprendizaje Profundo

1er Semestre 2026

Trabajo Práctico 2

Fecha de entrega: 17 de Abril 23:59 hs

Formato de entrega: Los archivos desarrollados deberán entregarse en un archivo comprimido (.zip) a través del Campus Virtual, utilizando el siguiente formato de nombre: `Apellido_Nombre_TP2.zip`. Se aceptará únicamente un archivo por estudiante. En caso de que el nombre del archivo no cumpla con la nomenclatura especificada, el trabajo no será corregido. Dentro del archivo .zip se deberá incluir un archivo Jupyter Notebook llamado *Entrega_ TP2.ipynb* con las celdas ejecutadas, que contenga los resultados y discusiones para cada inciso.
Se recomienda, en la medida de lo posible, no realizar todo el desarrollo dentro de los Jupyter Notebooks; en su lugar, se sugiere utilizar archivos `.py` para desarrollar el código, siguiendo las buenas prácticas de programación y modularización vistas en clase. Los archivos deben estar listos para que los correctores puedan correr el código. Caso contrario, **se restarán puntos.**
Limitaciones:

- Utilice exclusivamente NumPy para la implementación de funciones y/o clases.
- Utilice exclusivamente Pandas y Matplotlib/Seaborn para el manejo y gráfico de datos.
- No se permite el uso de librerías de Machine Learning como scikit-learn.
- No se permite el uso de herramientas de IA, salvo para la graficación de datos y resultados.

Trabajo Práctico 2: Clasificación y Ensemble Learning

Predicción de Rendimiento Estudiantil

El Ministerio de Educación de una provincia recopiló datos de estudiantes de 8 escuelas secundarias a lo largo de 6 semestres con el objetivo de construir un modelo predictivo que permita identificar tempranamente a estudiantes en riesgo de bajo rendimiento académico. Sin embargo, las escuelas difieren significativamente entre sí: tienen distintos niveles de exigencia, recursos, cantidad de alumnos por aula y contextos socioeconómicos.
El archivo *rendimiento_estudiantes_dev.csv* contiene los datos destinados al desarrollo del modelo, y el archivo *rendimiento_estudiantes_test.csv* contiene los datos destinados a la evaluación final (held-out). Dentro de cada archivo, cada fila corresponde al rendimiento de un estudiante en un semestre particular. Las features recolectadas se detallan a continuación.

Variable	Descripción
`horas_estudio`	Horas de estudio semanales promedio reportadas
`asistencia`	Porcentaje de asistencia a clases (0–100)
`nota_previa`	Calificación promedio del semestre anterior (0–10)
`horas_sueno`	Horas de sueño promedio por noche
`participacion`	Índice de participación en clase (0–10)
`horas_extracurricular`	Horas semanales en actividades extracurriculares
`acceso_internet`	1 si tiene acceso a internet de calidad en su hogar
`distancia_escuela_km`	Distancia en km entre el hogar y la escuela
`nivel_socioeconomico`	Índice socioeconómico del hogar (normalizado 0–1)
`tamano_clase`	Cantidad de estudiantes en el aula
`escuela`	Identificador de la escuela (A, B, C, . . . , H)
`semestre`	Semestre de recolección (2022-1, 2022-2, . . . , 2024-2)
`rendimiento`	**Variable objetivo.** Insuficiente / Regular / Bueno / Excelente

A los fines de este trabajo, la variable objetivo **rendimiento** se utilizará de dos formas:

- **Binaria**: 1 (aprobado) si rendimiento $\in$ {Regular, Bueno, Excelente}, 0 (desaprobado) si rendimiento = Insuficiente
- **Multiclase**: las 4 categorias originales de rendimiento.

1. Análisis Exploratorio y Preprocesamiento

1.1 Realizar un análisis exploratorio de los datos de desarrollo. Visualizar la distribución de cada variable, identificar valores faltantes, outliers y variables categóricas. Analizar la distribución de la variable objetivo (tanto en su versión multiclase como binaria).

1.2 Investigar la estructura de grupo del dataset. ¿Cómo varían las distribuciones de las features entre escuelas? ¿Existen features cuya correlación con el target cambia notablemente de una escuela a otra? ¿Cómo varía la proporción de clases entre escuelas y entre semestres? Visualizar estas relaciones con gráficos apropiados.

1.3 Aplicar las técnicas de limpieza y preprocesamiento que considere necesarias, justificando cada decisión.

2. Clasificación Binaria y Estrategias de Splitting

Para esta sección, considerar la versión binaria del target.

2.1 Implementar una clase de regresión logística binaria con regularización L2. Entrenar el modelo y evaluar su desempeño utilizando tres estrategias de partición diferentes:

- **Random Split (80/20)**: Partición aleatoria estratificada por la variable objetivo.
- **Group Split por escuela**: Utilizar los datos de 6 escuelas para entrenamiento y los datos de las 2 escuelas restantes para validación.
- **Temporal Split**: Utilizar los datos de los primeros 5 semestres para entrenamiento y el último semestre para validación.

Para cada estrategia, reportar:

- Matriz de confusión
- Accuracy, Precision, Recall, F1-Score
- Curva ROC y AUC-ROC
- Curva Precision-Recall y AUC-PR

2.2 Para cada estrategia de splitting, ajustar el hiperparámetro de regularización λ utilizando cross-validation (KFold aleatorio, GroupKFold por escuela). Para el caso temporal, utilizar un único split temporal como en el inciso anterior. Graficar F1 de validación vs λ para cada estrategia. ¿Resulta el mismo λ óptimo en los tres casos? Analizar brevemente.

2.3 Para cada feature, obtener la distribución de sus coeficientes de regresión logística utilizando cross-validation con K folds aleatorios y cross-validation con GroupKFold por escuela. Comparar la estabilidad (desvío estándar) de los coeficientes entre ambas estrategias de CV y responder: ¿Qué features presentan mayor inestabilidad de coeficientes bajo GroupKFold en comparación con KFold aleatorio? ¿Qué implica que un coeficiente sea inestable cuando se cambia la composición de escuelas en el entrenamiento? ¿En que contexto de uso se optaría por cada estrategia de splitting si buscamos la estimación mas realista de la performance en producción?

2.4 (OPCIONAL) Repetir la evaluación sin incluir la variable escuela como feature. ¿Cómo cambian los resultados en cada estrategia de splitting? ¿El gap entre random split y group split se reduce?

3. Clasificación Multiclase y Ensemble Learning

Para esta sección, considerar la versión multiclase del target. Las evaluaciones deben realizarse utilizando Group-K-fold por escuela.

3.1 Implementar y entrenar los siguientes modelos:

- Análisis Discriminante Lineal (LDA)
- Regresión logística multiclase con regularización.
- Random Forest utilizando entropía como criterio de división. Experimentar con distintos hiperparámetros (número de árboles, profundidad máxima, mínimo de muestras por hoja, etc.) y seleccionar la mejor configuración.

3.2 Para cada modelo, reportar las siguientes métricas en formato one-vs-all (un valor por clase):

- Matriz de confusión
- Accuracy, Precision, Recall, F1-Score
- Curva ROC y AUC-ROC
- Curva PR y AUC-PR

Presentar los resultados en tablas y gráficos comparativos.

3.3 Analizar la importancia de features del Random Forest. ¿Coincide con lo esperado?

4. Manejo de Desbalance de Clases

Para esta sección, considerar la versión binaria del target. Las evaluaciones deben realizarse utilizando Group-K-fold por escuela.

4.1 Entrenar un modelo de regresión logística binaria con regularización L2 aplicando cada una de las siguientes técnicas de rebalanceo al conjunto de entrenamiento de cada fold:

- Sin rebalanceo: entrenar el modelo directamente sobre los datos desbalanceados.
- Undersampling: eliminar muestras de la clase mayoritaria de manera aleatoria hasta que ambas clases tengan igual proporción.
- Oversampling mediante duplicación: duplicar muestras de la clase minoritaria de manera aleatoria, hasta que que ambas clases tengan igual proporción.

- Oversampling mediante SMOTE (Synthetic Minority Oversampling Technique): hasta que ambas clases tengan igual proporción.
- Cost re-weighting: en la función de costo, multiplicar los terminos que dependen de las muestras de la clase minoritaria por un factor $C = \frac{\pi_2}{\pi_1}$, donde π_1 es la probabilidad a-priori de la clase minoritoria y π_2 el de la clase mayoritaria. Esto efectivamente re-balancea la importancia de tener errores de clasificacion de ambas clases.

Evalúe el desempeño de cada modelo utilizando las mismas métricas que en la sección 2. Para las métricas escalares, presente los resultados en una tabla como la siguiente:

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-Score**	**AUC-ROC**	**AUC-PR**
Sin rebalanceo						
Undersampling						
Oversampling duplicate						
Oversampling SMOTE						
Cost re-weighting						

Para ajustar el hiperparámetro de regularización, puede utilizar F1-Score como métrica de performance.

4.2 Analizando los resultados obtenidos, justifique que técnica es la mas adecuada para esta situación.

5. Evaluación Final

5.1 Considerando los resultados obtenidos en los incisos anteriores, seleccionar el mejor modelo, técnica de rebalanceo y estrategia de splitting, tanto para el caso binario como para multiclase. Justificar brevemente la elección en cada caso.

5.2 Reentrenar con todos los datos de desarrollo y evaluar sobre los datos de testeo. Reportar todas las métricas correspondientes.

5.3 Como regla general, mas datos implica mejor performance. Supongamos que estamos interesados en recolectar más datos para mejorar el accuracy del modelo Random Forest multiclase (del inciso 3) en un 1 %. Estimar la cantidad de datos nuevos que sería necesario agregar.